

⚠ Le prof pénalise « l'IA sans comprendre ». Ne récite pas. Comprends, et **montre le code** (ouvre [src/nettoyage.py](#) ou [app_streamlit.py](#)). Parle lentement, regarde le jury.

🚀 À lancer AVANT de passer

```
cd dashboard-dvf
python3 main.py # génère la base (~10s)
streamlit run app_streamlit.py
```

Onglet déjà ouvert sur le dashboard. Teste 1 fois : un **filtre département (13)**, la **recherche d'une commune**, l'onglet **Géographie**.

📊 Chiffres à connaître

Transactions (brut → propre)	404 868 → 373 038
Prix médian national	2 667 €/m ²
Prix moyen national	3 387 €/m ²
Appartement / Maison (médian)	3 462 / 2 226 €/m ²
Département le + cher	Paris — 9 447 €/m ²
Le + abordable	Creuse — 1 474 €/m ²
Segments Éco / Std / Luxe	72 % / 20 % / 7 %
Bouches-du-Rhône	≈ 11 ^e rang national

🏗 Structure (souple : 10 → 30 min)

- Contexte : 400k ventes DVF → « lisible en 10 s ? » (1 min)
 - Données + le pb des données « sales » (1 min)
 - Pipeline ETL :
collecte→SQLite→nettoyage→fusion→features→dashboard (2-3 min)
 - DÉMO live Streamlit** : filtres, recherche, carte (3-6 min)
 - Insights : Paris, segments, maison vs appart, focus 13 (2-4 min)
 - Choix & limites + conclusion (1-2 min)
- Pour tenir 20-30 min : montre + de filtres en direct et ouvre le code (modules src/).

? Réponses express

Médiane vs moyenne ?

La médiane résiste aux valeurs extrêmes (châteaux, erreurs). Moyenne 3 387 vs médiane 2 667 → l'écart prouve qu'il y a des extrêmes.

prix_m2 ?

valeur_fonciere / surface_reelle, borné 500–15 000 €/m² (anti-aberrations).

Pourquoi supprimer ~8 % des lignes ?

Pas de prix/surface = pas de prix au m². Doublons + montants impossibles (négatifs, milliards). Je l'assume et l'affiche.

SQLite, pourquoi ?

Centraliser au lieu de fichiers éparpillés. 3 tables : raw_dvf, raw_insee, dvf_clean. Pandas lit via read_sql_query.

Fusion : quelle clé ?

code_departement (fiable). Les noms de communes DVF ne sont pas normalisés (« MARSEILLE 1ER ») → clé mauvaise = fusion ratée.

Jointure LEFT = garder toutes les ventes. Ajout INSEE = population → ventes/100k hab.

Pourquoi Streamlit ?

Framework Python → appli web interactive sans JS. Filtres + carte en direct. C'est l'outil vu en cours.

As-tu utilisé l'IA ?

Oui, autorisé pour le code — mais je comprends et je peux réexpliquer chaque partie. (*propose d'ouvrir un fichier*)

Améliorations ?

Données INSEE plus fines (revenus), filtres encore + poussés, plusieurs années pour une tendance.

🧠 Réflexes

- Si question sur le code → **ouvre le fichier** et montre la fonction.
- Carte = **st.map** : points par département, couleur = prix, taille = volume.
- « Données sales » assumées : c'est **80 % du travail data** (nettoyage).
- Le dashboard se recalcule **en direct** sur 373 038 lignes (pas figé).
- Respire. Tu connais ton projet mieux que personne dans la salle.